

TALLER HANDS-ON · 2 HORAS

Habla con tus documentos

RAG con Amazon Bedrock Knowledge Bases

AGENDA

Dos horas, 75% manos en el teclado

Tiempo	Bloque	Tipo
0:00	Bienvenida y entorno	Setup
0:10	¿Qué es RAG?	Teoría
0:25	Datos en S3 y Knowledge Base	**Hands-on**
0:55	Probar en la consola	**Hands-on**
1:10	Consultar con Python	**Hands-on**
1:35	Retos	**Reto**
1:50	Limpieza y cierre	Cierre

CÓMO FUNCIONA ESTE TALLER

Todo el material vive en un repositorio

Guía paso a paso

Cada módulo es un archivo Markdown con comandos listos para copiar.

Checkpoints

Al final de cada módulo sabes si vas bien antes de avanzar.

Levanta la mano

Si te atoras, un mentor te ayuda. Si terminas, ayuda a quien está a tu lado.

```
github.com/[ORG]/taller-rag-bedrock
```

MÓDULO 0 · 10 MIN

Elige tu ruta y entra a AWS

En el evento

1. Abre **catalog.workshops.aws/join**
2. Escribe el código
3. Clic en **Open AWS console**

[CÓDIGO]

Con tu cuenta

Entra con un usuario de IAM, no con el usuario raíz. Costo estimado: **menos de 1 USD** si haces la limpieza.

Región: **US East (N. Virginia) · us-east-1**. Después abre **CloudShell** en la barra superior.

DEMO EN VIVO · SIN RAG

¿Le creerías a esta respuesta?

```
$ python3 05_sin_rag.py

🙋 ¿Cuántos días de vacaciones da Cacao Labs en el primer año?

🤖 …
```

El modelo nunca ha leído los documentos de Cacao Labs. Va a decir que no sabe… **o va a inventar.**

EL PROBLEMA

Los LLMs saben mucho, pero no lo tuyo

1

No conocen tus datos

Nunca leyeron tu reglamento, tus manuales ni tus contratos.

2

Tienen fecha de corte

Su conocimiento se congela el día que terminó su entrenamiento.

3

Pueden alucinar

Cuando no saben algo, a veces responden algo falso con mucha seguridad.

RAG · RETRIEVAL-AUGMENTED GENERATION

Un examen a libro abierto.

Antes de responder, el modelo **busca** en tus documentos y **lee** lo relevante. No tiene que memorizar nada.

LAS PIEZAS

Cinco piezas forman un sistema RAG

Documentos

PDF, Word, Markdown… guardados en Amazon S3.

Chunks

Fragmentos de unos cientos de palabras.

Embeddings

Vectores que representan el significado. Titan V2.

Base vectorial

Busca los vectores más parecidos. S3 Vectors.

Modelo

Redacta la respuesta con los chunks. Nova 2 Lite.

💡 Chunks muy chicos pierden contexto. Chunks muy grandes mezclan temas.

EMBEDDINGS Y BÚSQUEDA SEMÁNTICA

Busca por significado, no por palabras

Pregunta: **"días de vacaciones"**

Texto en los documentos	¿Se parece?
"periodo de descanso anual"	**Muy cercano** · sin palabras en común
"prima vacacional del 50 %"	**Cercano**
"reembolso de taxi"	**Lejano**

```
"vacaciones" → [0.021, -0.334, 0.118, … 1024 números]
```

EL FLUJO COMPLETO

De la pregunta a la respuesta con citas



La cita dice de qué documento salió cada dato. Así puedes **verificar** en lugar de solo creer.

AMAZON BEDROCK KNOWLEDGE BASES

RAG administrado: tú configuras, Bedrock opera

Tú haces	Bedrock hace
Subes documentos a S3	Los lee y los parte en chunks
Eliges el modelo de embeddings	Genera y guarda los vectores
Presionas **Sync**	Detecta archivos nuevos, cambiados y borrados
Llamas a una API	Busca, arma el prompt, genera y agrega citas

Sin servidores, sin código de ingesta y sin administrar la base vectorial.

LO QUE VAMOS A CONSTRUIR

Cacaobot: el asistente de Cacao Labs

Cacao Labs es una startup ficticia de Cárdenas. Tiene 4 documentos internos: reglamento, gastos y viajes, seguridad de TI y onboarding.

FUENTE **Amazon S3**	EMBEDDINGS **Titan Text Embeddings V2**	BASE VECTORIAL **Amazon S3 Vectors**
ORQUESTACIÓN **Bedrock Knowledge Bases**	GENERACIÓN **Amazon Nova 2 Lite**	TERMINAL **AWS CloudShell + boto3**

MÓDULOS 2 Y 3 · HANDS-ON · 30 MIN

Crea tu Knowledge Base

Campo	Valor
Nombre	kb-cacao-labs
Fuente de datos	s3://taller-rag-<tu-cuenta>/docs/
Chunking	Default chunking
Embeddings	Titan Text Embeddings V2 · 1024
Base vectorial	**Quick create → Amazon S3 Vectors**

⚠ **No elijas OpenSearch Serverless:** se cobra por hora aunque no lo uses.

EL PASO QUE TODOS OLVIDAN

Sin Sync, tu KB está vacía.

1 · Sync

Data source → **Sync** → espera **Completed**.

2 · Copia el ID

```
export KB_ID="…"
```

3 · Prueba

Test Knowledge Base en la consola (módulo 4).

MÓDULO 5 · HANDS-ON · 25 MIN

Dos APIs, dos niveles

`retrieve`

Devuelve los chunks más parecidos y su score.

Sin modelo generativo. Tú decides qué hacer con los chunks.

```
01_retrieve.py
```

`retrieve_and_generate`

Busca, genera la respuesta y devuelve citas.

RAG completo en una llamada. Con sessionId recuerda la conversación.

```
02_rag.py · 03_chat.py
```

02_RAG.PY

RAG completo en una llamada

```
response = client.retrieve_and_generate(
    input={"text": "¿Cómo pido un reembolso?"},
    retrieveAndGenerateConfiguration={
        "type": "KNOWLEDGE_BASE",
        "knowledgeBaseConfiguration": {
            "knowledgeBaseId": KB_ID,
            "modelArn": model_arn(), # us.amazon.nova-2-lite-v1:0
        }})
print(response["output"]["text"]) # + response["citations"]
```

MÓDULO 6 · RETOS · 15 MIN

Elige tu reto

🥉 Agrega un documento

Sube la política de mascotas, haz Sync y pregunta por tu perro. **Todos hacen este.**

🥈 Filtra por metadatos

Busca solo en documentos de finanzas, personas o TI.

🥇 Rompe a tu asistente

Prueba un prompt injection y luego blinda el prompt.

🏆 Tus documentos

Sube tus apuntes o un reglamento. Sin datos personales.

MÓDULO 7 · LIMPIEZA · 5 MIN

¿Usaste tu cuenta? Borra en este orden

1. La Knowledge Base **kb-cacao-labs**
2. El vector bucket y su índice en **S3 → Vector buckets**
3. El bucket **taller-rag-<tu-cuenta>**
4. El rol de IAM de Bedrock (opcional)

¿Cuenta de evento? Se borra sola al terminar el taller.

¿QUÉ SIGUE?

De responder preguntas a tomar acciones

HOY

RAG

Responde con tus documentos y cita la fuente.

SIGUIENTE

Agentes

Usan la KB como herramienta y además actúan: registran, validan, recuerdan.

PRODUCCIÓN

AgentCore

Hospedaje, memoria, identidad y observabilidad para agentes.

Próximo taller: **[nombre y fecha del siguiente evento]**



¡Gracias!

⭐ Repo: **github.com/[ORG]/taller-rag-bedrock**

📝 Encuesta: **[enlace de la encuesta]**

💜 Síguenos en AWS Builder Center: **AWS User Group Cárdenas**